

TÜBİTAK 2209-A

Üniversite Öğrencileri Araştırma Projeleri Destekleme Programı

Finansal Zaman Serilerinde Çoğunluk Sınıfı (Majority Class) Tuzağının Aşılması: Hibrit Derin Öğrenme Mimarileri, Dikkat Mekanizmaları ve Geleneksel Finans Baseline Karşılaştırması

*BIST100 (THYAO) ve Emeklilik Yatırım Fonları (ALZ, AZS, AMZ) Üzerinde Yönsel
Tahmin ve Algoritma Körlüğü Analizi*

Proje Türü	TÜBİTAK 2209-A Araştırma ve Geliştirme Projesi
Araştırma Alanı	Finansal Makine Öğrenmesi, Aktüeryal Bilimler, Derin Öğrenme
Veri Varlıkları	THYAO (Günlük), Allianz Emeklilik Fonları (ALZ, AZS, AMZ - Haftalık)
Hedef Başvuru Dönemi	2026 / 2. Dönem
Proje Yürütücüsü / Ekip	Mehmet Ali KURT, Şevval DEMİR, Sude ...
Akademik Danışman	Dr. Övgücan KARADAĞ ERDEMİR (Hacettepe Üniversitesi, Aktüerya Bilimleri Bölümü)

1. Proje Özeti ve Anahtar Kelimeler

Bu araştırma projesi, finansal zaman serilerinin yönsel tahmininde karşılaşılan en kronik metodolojik problemlerden biri olan **Çoğunluk Sınıfı Tuzağını (Majority Class Illusion / Sinkhole)** derin öğrenme uzayında dekonstrükt etmeyi ve aşmayı hedeflemektedir. Literatürde yüksek doğruluk (Accuracy) oranları ile sunulan birçok finansal yapay zeka modelinin, gerçekte verideki yönsel yapıları öğrenmek yerine, baskın piyasa trendini ezberleyerek tek yönlü tahmin (bütün örnekler "yukarı" veya "aşağı" deme eğilimi) ürettiği ampirik olarak belgelenmiştir. Bu durum, finansal risk yönetiminde yıkıcı sonuçlar doğurabilecek bir "Doğruluk Paradoksu" yaratmaktadır.

Proje kapsamında, ön çalışmalarda izole edilen bu metodolojik körlüğü kırmak amacıyla saf derin öğrenme tabanlı 6 farklı gelişmiş mimari kurgulanmıştır: **BiLSTM, 1D-CNN+BiLSTM Hibrit, BiLSTM+Attention, 1D-CNN+BiLSTM+Attention, Temporal Convolutional Networks (TCN) ve Transformer Encoder**. Modeller, Borsa İstanbul'un lokomotif hisselerinden THYAO günlük verileri ile farklı risk profillerine sahip TEFAS BES fonları (ALZ, AZS, AMZ haftalık verileri) üzerinde, sızıntısız bir kayan pencere (Rolling/Walk-Forward Validation) mekanizmasıyla eğitilecektir. Geliştirilen modellerin gerçek öğrenme kapasitesi, geleneksel finanstaki teknik analistlerin kararlarını taklit eden deterministik bir **"Majority Rules Technical Analysis Matrix" (Voting Classifier)** kontrol grubu ile adil bir biçimde karşılaştırılacaktır. Başarı ölçütü olarak salt Accuracy yerine Duyarlılık (Sensitivity), Özgöllük (Specificity) ve Dengeli Doğruluk (Balanced Accuracy) kriterleri esas alınarak havuzlanmış matrisler üzerinden kesin binom testleri uygulanacaktır.

Anahtar Kelimeler: Çoğunluk Sınıfı Tuzağı, Finansal Zaman Serileri, Hibrit Derin Öğrenme, Dikkat Mekanizmaları (Attention), TCN, Transformer Encoder, Çoğunluk Kuralı Matrisi.

2. Giriş, Literatür Özeti ve Araştırma Boşluğu

Eugene Fama (1970) tarafından ortaya konan Etkin Piyasalar Hipotezi (Efficient Market Hypothesis - EMH), finansal varlık fiyatlarının mevcut tüm bilgiyi anında yansıttığını ve dolayısıyla fiyat hareketlerinin rassal bir yürüyüş (Random Walk) izleyerek tahmin edilemez olduğunu savunur. Ancak modern finansal veri bilimi literatürü, doğrusal olmayan dinamiklerin, kurumsal momentumun ve mikro-yapısal anomalilerin derin yapay sinir ağları tarafından yakalanabileceğini öne sürmektedir. Bu bağlamda, Hochreiter & Schmidhuber (1997) tarafından geliştirilen Uzun Kısa Vadeli Bellek (LSTM) ağları ve LeCun vd. (2015) tarafından popülerleştirilen Evrişimli Sinir Ağları (CNN), zaman serisi yön tahmininde birincil araçlar haline gelmiştir. Van der Burgt (2023), NASDAQ100 endeksi üzerinde ARIMA, LSTM ve 1D-CNN modellerini karşılaştırarak teknik göstergelerin derin öğrenme modellerindeki üstünlüğünü ortaya koymuştur.

Ancak mevcut literatürde çok kritik bir metodolojik açık bulunmaktadır: Finansal zaman serileri, yapısal rejim değişiklikleri ve uzun vadeli trend eğilimleri nedeniyle doğal olarak dengesiz sınıf dağılımlarına (Class Imbalance) sahiptir. Örneğin, sürekli yükselen boğa piyasası rejimlerinde veya para piyasası

fonlarında (ALZ gibi) verinin %90'ından fazlası "yukarı" yönlü hareket içerir. Standart kayıp fonksiyonları (Binary Crossentropy) ile eğitilen derin öğrenme modelleri, optimizasyon esnasında en zahmetsiz yolu seçerek her güne "yukarı" tahmini yapma eğilimine girer (Majority Class). Bu durum genel doğruluğu (Accuracy) yapay bir şekilde yükseltirken, modelin düşüş hareketlerini tahmin etme yeteneğini (Specificity) tamamen sıfıra indirmektedir. Valverde-Albacete & Pelaez-Moreno (2014) bu durumu "Doğruluk Paradoksu" (Accuracy Paradox) olarak adlandırmış ve salt doğruluk metriğinin model değerlendirmede yaratacağı körlüğü bilimsel olarak ispatlamıştır.

Literatürdeki Araştırma Boşluğu (Research Gap)

Finansal yapay zeka literatürünün %80'i, modellerinin ürettiği yüksek Accuracy oranlarını raporlarken Özgöllük (Specificity) ve Dengeli Doğruluk (Balanced Accuracy) metriklerini gizlemekte veya tartışmamaktadır. Gelişmekte olan piyasalar (BIST) ve emeklilik fonları özelinde, modellerin bu çoğunluk tuzağına ne oranda düştüğü, mimari değişikliklerin (Attention, TCN, Transformer) ve geleneksel oylama mantığının bu tuzağı kırıp kıramayacağı sistematik olarak incelenmemiştir. Projemiz bu yapısal açığı kapatmayı hedeflemektedir.

3. Amaç, Hipotezler ve Yenilikçi Yön

Projenin temel amacı, BIST100 ve BES fon verilerinde derin öğrenme modellerinin yakalandığı Çoğunluk Sınıfı (MC) tuzağını deşifre etmek, bu tuzağı kırarak gerçek ayırt etme kapasitesine sahip dengeli modeller geliştirmek ve derin ağların finansal yön tahminindeki sınırlarını ampirik olarak çizmektir.

3.1. Proje Hipotezleri

- **Hipotez 1 (Mimari Direnç)**: Yerel ve zamansal filtreleme yapan 1D-CNN-BiLSTM hibrit mimarisi ve zamansal bağımlılıkları genişletilmiş konvolüsyonlarla işleyen TCN modelleri, tüm sekansı tek skaler özete sıkıştıran standart LSTM ağlarına kıyasla Çoğunluk Sınıfı tuzağına karşı daha yüksek istatistiksel direnç sergiler.
- **Hipotez 2 (Dinamik Odaklanma)**: BiLSTM modellerine eklenen Dikkat (Attention) mekanizması, modelin sabit bir "hep yukarı" kararına saplanmasını engelleyerek, tahmin anında geçmiş penceredeki anomali veya dönüm noktası içeren spesifik günlere odaklanmasını sağlar ve Specificity değerini anlamlı şekilde artırır.
- **Hipotez 3 (Sinyal Tersinmesi)**: Teknik analiz göstergelerinin ham hallerinin derin ağlar tarafından işlenmesi esnasında oluşan aşırı gürültü, modellerde sistematik ters tahmin (Signal Inversion) doğurur; bu durum geleneksel bir Çoğunluk Kuralı (Voting) Matrisi baseline'ı ile izole edilebilir.

3.2. Yenilikçi Yön (Özgün Katkı)

Bu çalışma basit bir "fiyat tahmin botu" projesi değildir. Projenin yenilikçi yönü, bir hatayı (modelin MC'ye çökmesi veya ters yöne çalışması) bir keşfe dönüştürmesidir. Modellerin "kara kutu" yapısı, Attention ağırlıkları çekilerek görselleştirilecek ve modelin hata yaparken finansal göstergelerdeki hangi yapısal kırılmalara kıldığı (XAI - Açıklanabilir Yapay Zeka bağlamında) ilk kez ortaya konacaktır. Ayrıca geleneksel finansın oylama mantığı ile modern derin öğrenme ilk kez bir "baseline" savaşına sokulacaktır.

4. Metodoloji ve Denenecek Derin Öğrenme Mimarileri

Çoğunluk sınıfı tuzağını kırmak için proje kapsamında tasarlanan ve sırasıyla test edilerek hiperparametre uzayında (Grid Search) taranacak 6 derin öğrenme mimarisi aşağıda teknik detaylarıyla kurgulanmıştır:

4.1. BiLSTM (Çift Yönlü Uzun Kısa Vadeli Bellek - Taban Model)

Geleneksel LSTM katmanlarının aksine, veriyi hem geçmişten geleceğe (ileri yönlü) hem de gelecekte geçmişe (geri yönlü) işleyen iki bağımsız katmanın birleşimidir. Hücre içi 4-kapı mekanizması (forget, input, aday hücre, output kapıları) şu formüllerle çalışır:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad | \quad i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

BiLSTM katmanı, zaman serisindeki ardışık bağımlılıkları iki yönlü kavrayarak modelin tek yönlü trend gürültüsüne kapılmasını zorlaştırır. Bu model projenin derin öğrenme taban kontrol noktası olacaktır.

4.2. 1D-CNN + BiLSTM (Sıralı Hibrit Mimari)

Veri seti BiLSTM katmanına beslenmeden önce ardışık Evrişim (*Conv1D*) ve Maksimum Havuzlama (*MaxPooling1D*) katmanlarından geçirilir. 1D-CNN katmanındaki lokal filtreler, zaman serisindeki anlık trend kırılımlarını, momentum sıçramalarını ve yerel örüntüleri süzerek bir özellik haritası (*feature map*) çıkarır. Konvolüsyon formülü şu şekildedir:

$$y_i = \text{ReLU}(b + \sum_{k=0}^{K-1} w_k \cdot x_{i+k})$$

CNN katmanı baskın piyasa trendinin yarattığı makro gürültüyü süzdüğü için, arkasından gelen BiLSTM katmanı çoğunluk sınıfının tuzağına düşmek yerine, CNN tarafından vurgulanmış azınlık sınıfı (düşüş/dönüş sinyalleri) kalıplarına odaklanabilir. Ön çalışmalarındaki "CNN'in daha yüksek MC direnci göstermesi" bulgusu bu yapıya dayanmaktadır.

4.3. BiLSTM + Attention (Zamansal Dikkat Mekanizması)

BiLSTM katmanının tüm zaman adımlarındaki gizli durum çıkışları (h_t) toplanarak doğrudan sınıflandırıcıya verilmez. Araya eklenen Attention katmanı, her bir zaman adımının nihai karara olan etkisini dinamik olarak ağırlıklandırır. Skorlama ve bağlam (*context*) vektörü hesabı:

$$e_t = \tanh(W_a \cdot h_t + b_a) \quad | \quad \alpha_t = \exp(e_t) / \sum \exp(e_k) \quad | \quad c = \sum \alpha_t \cdot h_t$$

Bu mekanizma sayesinde model, örneğin *Input=6* günlük bir pencerede her güne aynı önemi vermek yerine, hacmin aniden patladığı veya RSI göstergesinin aşırı satıma geçtiği spesifik "3. güne" veya "5. güne" yüksek dikkat ağırlığı (α_t) atar. Bu dinamik yapı, modelin monoton bir "ezber kararına" (MC) saplanmasını engeller.

4.4. 1D-CNN + BiLSTM + Attention (Tam Entegre Kombinasyon)

Süreç zincirleme olarak kurgulanır: 1D-CNN katmanı lokal gürültüyü süzerek özellikleri çıkarır, BiLSTM zamansal bağımlılıkları çift yönlü hafızaya alır, Attention katmanı ise bu hafıza içindeki en kritik anomali anlarını seçerek ağırlıklandırır. Çoğunluk sınıfı tuzağına karşı teorik olarak en dayanıklı kombine yapıdır.

4.5. TCN (Temporal Convolutional Networks - Zamansal Evrişimli Ağlar)

Tekrarlı (RNN/LSTM) yapıları tamamen ortadan kaldıran, nedensel (causal) ve genişletilmiş (dilated) konvolüsyon bloklarından oluşan saf bir mimaridir. *padding="causal"* kuralı sayesinde gelecekteki bilginin geçmişe sızması (data leakage) kesin olarak engellenir. Genişleme faktörü (d) sayesinde, parametre patlaması yaşamadan çok geniş bir geçmiş zaman ufku (receptive field) görebilir. LSTM'lerin finansal serilerdeki en büyük zaafı olan "gradyan sönümlenmesi veya patlaması nedeniyle uzun vadede baskın sınıfa teslim olma" eğilimi TCN mimarisinde yapısal olarak minimize edilmiştir.

4.6. Transformer Encoder (Self-Attention Tabanlı Mimari)

Zaman sırasını adım adım işlemek yerine, *Multi-Head Self-Attention* mekanizması ile zaman penceresindeki tüm günlerin ve tüm özelliklerin birbiriyle olan ilişkisini aynı anda hesaplar. Hacim ile dünün kapanış fiyatı, iki gün önceki RSI ile bugünün MACD'si arasındaki çapraz korelasyonları doğrudan "Query, Key, Value" matris çarpımlarıyla ağırlıklandırır:

$$Attention(Q, K, V) = softmax((Q \cdot K^T) / \sqrt{d_k}) \cdot V$$

Transformer mimarisi, doğrusal ve ardışık olmayan finansal şokları yakalamada en yüksek kapasiteye sahip model olarak MC tuzağının kırılmasında en uç sınır kurgusunu oluşturacaktır.

5. Geleneksel Finans Baseline'ı: Majority Rules Technical Analysis Matrix

Modellerin gerçekten derin bir doğrusal olmayan örüntü mü öğrendiğini, yoksa basit bir indikatör oylamasına mı yenik düştüğünü test etmek için projeye geleneksel finasta köklü bir rakip eklenmiştir: **Majority Rules Technical Analysis Matrix (Çoğunluk Kuralı Teknik Analiz Matrisi).**

Bu sistem deterministik bir *Voting Classifier* (Oylama Sınıflandırıcısı) mantığıyla çalışır. Belirlenen N adet geleneksel teknik analiz indikatörü (RSI, MACD, EMA Kesişimi, Stochastic Oscillator, Momentum, Bollinger Bantları, Bollinger Genişliği, Çift Hareketli Ortalama, Williams %R, ROC) her t zaman dilimi için tamamen bağımsız ve kurallı olarak ikili sinyal üretir ($I_k \in \{0, 1\}$). Nihai karar mekanizması çoğunluğun oyuna dayanır:

$$\hat{y}_t = 1 \text{ eğer } \sum_{k=1}^N I_k > N/2 \text{ else } \hat{y}_t = 0$$

Bu matris proje kurgusunda iki kritik fonksiyonda kullanılacaktır:

1. **Zorlu Bir Kontrol Grubu (Competitor Baseline):** Eğer tasarlanan BiLSTM, TCN veya Transformer modelleri bu basit kurallı matrisin Balanced Accuracy performansını geçemiyorsa, derin öğrenme modellerinin finansal gürültü içinde boğulduğu ve katma değer üretemediği ampirik olarak kanıtlanacaktır.
2. **Meta-Özellik Mühendisliği (Meta-Feature):** 10 indikatörün ürettiği ham sinyallerin ortalaması ($Score = (\sum L_k) / N$), derin öğrenme modellerine 15. bir "girdi özelliği" olarak beslenecektir. Böylece ağ, devasa bir gürültü yığını yerine, indikatörlerin kurumsal uzlaşısı skorunu doğrudan bir "duyarlılık proxy'si" olarak okuyabilecektir.

6. Veri Kümesi, Ön İşleme ve Doğrulama Stratejisi

Projenin veri kurgusu ve sızıntı önleme mekanizmaları, akademik geçerliliği korumak adına katı kurallara bağlanmıştır.

6.1. Veri Varlıkları ve Sınıf Dağılımları

Çalışmada zıt dinamiklere sahip iki veri frekansı kullanılacaktır:

1. **THYAO:** Yahoo Finance kaynaklı, 2018-2026 dönemini kapsayan günlük 2.085 satırlık devasa bir gürültülü veri kümesi. Sınıf dağılımı (**Out=3** için) %51.6 Up / %48.4 Down ile oldukça dengelidir.
2. **Emeklilik Fonları (ALZ, AZS, AMZ):** TEFAS kaynaklı, 2021-2026 dönemini kapsayan haftalık 262 gözlemlik dar veri kümesi. Sınıf dağılımları risk profiliyle doğrudan ilişkilidir: ALZ %100 Up (düşüş günü yok - saf MC kontrol grubu), AZS %75.7 Up / %24.3 Down (orta dengesiz), AMZ %81.1 Up / %18.9 Down (yüksek dengesiz).

6.2. Veri Sızıntısı (Data Leakage) ve Look-Ahead Bias Önleme Boru Hattı

Ön çalışmalardaki hoca önerilerine sadık kalınarak, veri sızıntılarını sıfırlayan şu mimari adımlar atılmıştır:

- **preProcess Train-Only Kuralı:** *caret::preProcess* MinMax veya Standardizasyon ölçeklendirme parametreleri sadece Eğitim (Train) seti üzerinden hesaplanacak (**fit**), Doğrulama ve Test setlerine ise bu parametreler sadece uygulanacaktır (**transform-only**). Test setinin maksimum/minimum değerlerinin eğitime sızması kesin olarak engellenmiştir.
- **Split-İçi Etiketleme (Create Label):** Yönsel etiketler ($P_{t+Out} > P_t \rightarrow 1$) tüm ham veri üzerinde tek seferde oluşturulmayacaktır. Veri Train/Val/Test olarak kronolojik bölündükten sonra, her split kendi içinde etiketlenecektir. Böylece Train setinin son satırlarının, Doğrulama setinin ilk günlerindeki fiyat hareketlerine bakarak etiket alması (Look-ahead bias) imkansız hale getirilmiştir.

6.3. Kayan Pencere (Rolling Window) ve Havuzlanmış Matris (N=96) Stratejisi

Zaman serisindeki rejim değişikliklerini (Concept Drift) izlemek amacıyla model doğrulaması **Rolling Window** mantığıyla zaman içinde kaydırılarak yürütülecektir. Modellerin başlangıç ağırlıklarının şans faktörüne (Lucky Seed) bağlı kalmasını engellemek amacıyla 3 farklı tohum (Seed 23, 27, 98) kümülatif olarak havuzlanacaktır. Tekil iterasyonların (N=32) ondalıklı doğru tahmin paradoksu yaratmasını önlemek adına, 3 seed'in karmaşıklık matrisleri toplanarak **Pooled Confusion Matrix (N = 32 × 3 = 96)** elde edilecek ve tüm nihai metrikler bu kararlı matris üzerinden raporlanacaktır. İstatistiksel anlamlılık, null hipotezin ($H_0: Acc = 0.50$) sınıandığı tek-örneklem kesin binom testi ile $p < 0.05$ eşliğinde ölçülecektir.

7. Performans Metrikleri ve Başarı Ölçütleri

Çoğunluk sınıfı tuzağını deşifre etmek için ham Doğruluk (Accuracy) metriği birincil ölçüt olmaktan çıkarılmıştır. Projedeki tüm kararlar ve şampiyon model seçimleri sağa yaslı şu formüller üzerinden yürütülecektir:

$$\text{Doğruluk (Accuracy)} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Duyarlılık (Sensitivity / Recall)} = TP / (TP + FN) \quad [\text{Yükselişleri Doğru Tahmin Etme Oranı}]$$

$$\text{Özgöllük (Specificity)} = TN / (TN + FP) \quad [\text{Düşüşleri Doğru Tahmin Etme Oranı}]$$

$$\text{Dengeli Doğruluk (Balanced Accuracy - BA)} = (Sensitivity + Specificity) / 2$$

$$F1\text{-Skoru} = 2 \cdot (Hassasiyet \cdot Duyarlılık) / (Hassasiyet + Duyarlılık)$$

Bir modelin Majority Class'a düşüp düşmediği şu geniş tanım matrisiyle denetlenecektir: **Specificity = 0** VEYA **Sensitivity = 0** VEYA **Specificity = NaN** (test setinde hiç düşüş olmaması durumu). Bu 3 koşuldan birini sağlayan model, genel doğruluğu kaç olursa olsun "başarısız/ezberci" kabul edilecektir. Gerçek başarı ölçütü, modelin adil karşılaştırmada kendi ufku olan **Out** değerindeki Naive Baseline doğruluğunu ve Majority Rules kurallı matris performansını istatistiksel olarak ($p < 0.05$) geride bırakmasıdır.

8. İş Paketleri, Zaman Planı ve Başarı Kriterleri

Projenin 5 aylık takvimi ve iş paketlerinin dağılımı resmi şablona uygun olarak planlanmıştır:

İş Paketi No	İş Paketi Adı ve İçeriği	Hedeflenen Çıktı / Milestone	Zaman Aralığı
İP 1	Veri Altyapısının Genişletilmesi ve Teknik Analiz Oylama Matrisinin Kurulması (THYAO + BES)	10 indikatörlü kurallı matrisin R/Python üzerinde tamamlanması, meta-özelliğin hazır edilmesi.	1 Haziran - 30 Haziran 2026
İP 2	Gelişmiş Derin Öğrenme Mimarilerinin Entegrasyonu (CNN-BiLSTM, Attention, TCN, Transformer)	Keras/TensorFlow üzerinde 6 modelin sızıntısız boru hattına entegre edilmesi.	1 Temmuz - 31 Temmuz 2026

İş Paketi No	İş Paketi Adı ve İçeriği	Hedeflenen Çıktı / Milestone	Zaman Aralığı
İP 3	Rolling Window Grid Search ve Çoklu Tohum (3-Seed) Model Eğitim Koşulları	810+ parametre kombinasyonunun CPU/GPU üzerinde eğitilmesi ve N=96 havuzlanmış sonuç dökümlerinin alınması.	1 Ağustos - 31 Ağustos 2026
İP 4	Metrik Analizleri, XAI Dikkat Haritalarının Çıkarılması ve Kontrol Grupları ile Çarpıştırma	Attention ağırlıklarının ısı haritalarına dökülmesi, Baseline ve Kurallı Matris karşılaştırma grafikleri.	1 Eylül - 30 Eylül 2026
İP 5	TÜBİTAK 2209-A Resmi Başvuru Formunun Yazımı, Akademik Raporlama ve Danışman Onayı	E-TÜBİTAK üzerinden tüm proje dökümünün yüklenmesi ve onay süreçlerinin tamamlanması.	1 Ekim - 31 Ekim 2026

9. Kaynakça

- [1] Van der Burgt, J. (2023). *Navigating trends: A comparison of ARIMA, LSTM and 1D-CNN for stock price direction prediction*. Tilburg University Thesis.
- [2] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- [3] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [4] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521, 436–444.
- [5] Valverde-Albacete, F. J., & Pelaez-Moreno, C. (2014). 100% classification accuracy considered harmful: The normalized information transfer factor explains the accuracy paradox. *PLOS ONE*.
- [6] Kang, B., et al. (2019). Decoupling representation and classifier for long-tailed recognition. *International Conference on Learning Representations (ICLR)*.
- [7] Livieris, I. E., Pintelas, E., & Pintelas, P. (2020). A CNN-LSTM model for gold price time-series forecasting. *Neural Computing and Applications*, 32, 17351-17360.